

ARIA-GOLF v1-v5：结构差异与模型公式

内部架构说明


2026 年 6 月 14 日

摘要

本文把 ARIA-GOLF v1-v5 的配置差异整理成一个便于理解和展示模型比较说明。五个版本共享相同的编码器系列、观测到的 F_0 条件、LF 声门流振荡器、白噪声发生器、room filter 以及 multi-scale spectrogram loss。真正的结构差异集中在两个位置：一是 v1-v3 逐步调整的解析声道级联滤波器，二是 v3-v5 改动的谐波/噪声激励拓扑。在所有版本中，谐波支路和噪声支路先在 source level 合成为一个激励信号 s ，然后这个合成后的 source 再整体经过一次 VocalTractCascade / LPC-like 声道滤波器。下面的公式把这些变化写成一个可解释的 ablation sequence。

如何阅读这五个版本

最简单的读法是：v1-v5 不是五个互不相关的系统，而是沿着两条轴线展开的结构消融。第一条轴线是 v1-v3：它们主要在调整解析 vocal tract，即显式 formant control、bandwidth constraint、spectral tilt 和 learned residual all-pole capacity 之间的平衡。第二条轴线是 v3-v5：v4 和 v5 保留 v3 的 vocal tract，只改变 excitation mixture，因为 v3 剩下的主要问题来自 additive harmonic-plus-noise source 中的高频周期性条纹。



v1→v2: 收紧 F/B 范围 v2→v3: 恢复 spectral tilt

图 1: ARIA-GOLF v1-v5 的概念谱系。v1-v3 应读作声道滤波器的逐步改进；v4 和 v5 是针对同一个高频 excitation artifact 的两种修复方案。v1 同时也是没有显式 formant supervision 的 baseline。




图 2: 三种 excitation topology。Additive synthesis 可以增加噪声地板, 但不能抑制已经存在的周期性谐波。v4 和 v5 引入 per-band harmonic/noise mixture, 因此可以把一部分高频周期性能量转成 shaped noise。

1 共享的 Source-Filter 骨架

令 x 表示输入波形, $F_{0,k}$ 表示观测到的 frame-rate 基频轨迹。编码器预测 frame-rate control streams:

$$\mathbf{c}_k = E_\theta(x, F_{0,k}), \quad (1)$$

其中最后一层 projection 的宽度由 decoder 声明的 control splits 决定。上采样之后, LF source 的相位由下式得到:

$$\phi_n = \phi_{n-1} + 2\pi \frac{F_{0,n}}{f_s}, \quad (2)$$

deterministic harmonic source 为:

$$h_n = v_n g_{\text{LF}}(\phi_n; R_{d,n}), \quad (3)$$

其中 $v_n = \mathbb{I}[F_{0,n} > 0]$ 是 voicing gate, R_d 控制 LF glottal-flow shape。每个版本都有一个白噪声激励 $\eta_n \sim \mathcal{N}(0, 1)$ 。模型首先把 harmonic branch 和 noise branch 合成为一个 source/excitation signal $s^{(m)}$, 然后最终波形总是:

$$\hat{x} = H_{\text{room}} * (H_{\text{VT}}^{(m)} * s^{(m)}), \quad (4)$$

其中 $m \in \{1, \dots, 5\}$ 表示模型版本。因此, 各版本只在 version-specific source $s^{(m)}$ 和 vocal-tract filter $H_{\text{VT}}^{(m)}$ 上不同。实现上, 这是对合成后的 source 做一次 vocal-tract filtering, 也就是 $\text{LPC}(h + \text{noise})$, 而不是先分别滤波再相加。由于 end filter 是线性的, 两种写法在数学上等价; 但从架构和代码顺序看, source-level 合成再过 vocal tract 是更清楚的读法。

2 Vocal-Tract Cascade

解析 vocal tract 包含一个 gain term、一个可选 spectral-tilt term、两个 deterministic all-pole formant sections, 以及若干 learned biquad sections:

$$H_{\text{VT}}^{(m)}(z) = G_n T_{\alpha,n}^{\delta_m}(z) \prod_{j=1}^2 P(z; F_{j,n}, B_{j,n}) \prod_{\ell=1}^{L_m} B_{\ell,n}(z). \quad (5)$$

这里 $\delta_m = 1$ 表示启用 spectral tilt, $\delta_m = 0$ 表示不启用。Learned residual sections $B_{\ell,n}$ 用来吸收显式 F1/F2 poles 没有覆盖到的 vocal-tract detail。下表报告的是 16 kHz F024 配置, 也就是 v4/v5 所在的配置。

版本	Tilt δ_m	Learned L_m	F1 range	F2 range	B1/B2 range	LPC order
v1	1	6	150–1300	600–3200	30–330 / 30–430	18
v2	0	7	200–1000	700–3000	50–200 / 50–250	18
v3	1	6	150–1300	600–3200	50–200 / 50–250	18
v4	1	6	150–1300	600–3200	50–200 / 50–250	18
v5	1	6	150–1300	600–3200	50–200 / 50–250	18

表 1: 16 kHz F024 配置下 v1–v5 的 vocal-tract 差异。v4 和 v5 继承 v3 的 vocal-tract design, 它们的变化发生在 excitation topology。

这里的 nominal LPC order 按 biquad-like sections 的数量计算:

$$O_m = 2(\delta_m + 2 + L_m). \quad (6)$$

因此 16 kHz 下 v1/v3/v4/v5 的 vocal tract 是 $2(1+2+6) = 18$, 而 v2 是 $2(0+2+7) = 18$ 。Tilt section $T_\alpha(z)$ 是一个 degenerate biquad, 只有一个 real pole, 所以旧注释里可能会把 tilt-enabled 16 kHz model 写成 effective pole count 17。本文统一使用 nominal section-count convention。

采样率 / speaker	Nominal LPC order	v1 L_m	v2 L_m	v3 L_m
16 kHz / F024	18	6	7	6
22 kHz / LJSpeech	22	8	9	8
24 kHz / CSMSC	22	8	9	8

表 2: Learned residual cascade 的采样率依赖性。解析 F1/F2 controls 和 spectral tilt 在概念上保持不变; 更高采样率使用更多 learned biquads 来覆盖额外的高频细节。

3 各版本公式

3.1 v1: 第一个 Analytic-Formant Baseline

v1 引入了带 spectral tilt 的可解释 F1/F2 vocal-tract cascade, bandwidth 约束较宽, 并包含 6 个 learned residual biquads:

$$H_{VT_n}^{(1)}(z) = G_n T_{\alpha,n}(z) \prod_{j=1}^2 P(z; F_{j,n}, B_{j,n}) \prod_{\ell=1}^6 B_{\ell,n}(z), \quad (7)$$

$$s_n^{(1)} = h_n + (H_{N_n}^{\text{exp}} * \eta)_n. \quad (8)$$

Additive excitation 可以抬高噪声地板, 但不能削弱 h_n 中已经存在的 coherent high-frequency harmonics。需要特别注意的是, F024 训练 recipe 中 v1 的 F1/F2 control 没有显式 formant supervision, 它们只通过 reconstruction objective 间接形成, 因此 v1 是 formant control 最松的 baseline。

3.2 v2: 无 Spectral Tilt 的更强 Formant Control

v2 去掉 tilt branch, 收紧 F1/F2 和 B1/B2 的范围, 并增加一个 learned biquad:

$$H_{VT_n}^{(2)}(z) = G_n \prod_{j=1}^2 P(z; F_{j,n}, B_{j,n}) \prod_{\ell=1}^7 B_{\ell,n}(z), \quad (9)$$

$$s_n^{(2)} = h_n + (H_{N_n}^{\text{exp}} * \eta)_n. \quad (10)$$

v2 的目的在于增强 formant manipulability; 但去掉 tilt 后, broad spectral slope 就必须更多地由 residual sections 去解释。

3.3 v3: 当前 Vocal-Tract Base

v3 恢复 spectral tilt, 同时保留 v2 中更紧的 bandwidth constraints, 并回到 6 个 learned biquads:

$$H_{VT_n}^{(3)}(z) = G_n T_{\alpha,n}(z) \prod_{j=1}^2 P(z; F_{j,n}, B_{j,n}) \prod_{\ell=1}^6 B_{\ell,n}(z), \quad (11)$$

$$s_n^{(3)} = h_n + (H_{N_n}^{\text{exp}} * \eta)_n. \quad (12)$$

这是最强的 analytic vocal-tract baseline: 它同时包含 F1/F2 control、bounded bandwidths、spectral tilt 和 residual all-pole capacity。它的主要弱点仍然是 additive-only excitation, 因此在强 voiced region 里可能留下 high-frequency harmonic stripes。

3.4 v4: Decoupled Band-Aperiodicity Source

v4 保留 v3 的 vocal tract, 但加入一个显式 aperiodicity filter $A_n(\omega) \in [0, 1]$, 并带有 rising high-frequency prior:

$$H_{VT_n}^{(4)}(z) = H_{VT_n}^{(3)}(z), \quad (13)$$

$$A_n(\omega) = \sigma(a_n(\omega) + b_{\text{HF}}(\omega)), \quad (14)$$

$$S_n^{(4)}(\omega) = (1 - A_n(\omega))Y_n(\omega) + A_n(\omega)H_{N_n}^{\text{exp}}(\omega)N_n(\omega). \quad (15)$$

这里 $Y_n(\omega)$ 和 $N_n(\omega)$ 分别是 harmonic source 和 white noise 的 short-time spectra。Noise-colour filter H_N 保持 unbounded, 而 A 单独控制 harmonic/noise mixture。因此 v4 是修复 high-band harmonic-stripe artifact 最清晰、最原则化的版本。

3.5 v5: Minimal Bounded Crossfade

v5 也保留 v3 的 vocal tract, 但把 noise filter 本身用作 bounded crossfade:

$$H_{VT_n}^{(5)}(z) = H_{VT_n}^{(3)}(z), \quad (16)$$

$$q_n(\omega) = \sigma(r_n(\omega)), \quad (17)$$

$$S_n^{(5)}(\omega) = (1 - q_n(\omega))Y_n(\omega) + q_n(\omega)N_n(\omega). \quad (18)$$

等价地，用 operator form 可以写成：

$$s^{(5)} = (I - Q)h + Q\eta = h + Q\eta - Qh. \quad (19)$$

这是最小结构改动：不增加额外 aperiodicity head，但同一个 bounded filter 必须同时承担 noise colour 和 aperiodicity weight 两个职责。

4 作为 Ablation Sequence 的解释

版本	Formant loss	Smoothness	Residual reg.	Batch $\times$ steps	Data passes
v1	0	—	—	$64 \times 40k$	$1 \times$
v2	1.5	—	0.02	$64 \times 80k$	$2 \times$
v3	2.0	0.05	0.02	$128 \times 40k$	$2 \times$
v4	2.0	0.05	0.02	$128 \times 40k$	$2 \times$
v5	2.0	0.05	0.02	$128 \times 40k$	$2 \times$

表 3: F024 比较中的训练和 supervision 差异。关键修正是：v1 没有显式 formant supervision；不应再使用“light supervision”的说法。

版本	意图	主要变化	代价 / 风险
v1	第一个 analytic-formant ARIA	Tilt on, 宽 bandwidth, 无 formant supervision	重建尚可，但 formant control 松散、约束较弱
v2	更强 formant control	Tilt off, 收紧 bandwidth, 七个 learned sections	Control 改善，但 spectral slope 不够显式
v3	当前 base	Tilt restored, 紧 bandwidth, 强 supervision	操控较好，但 additive source artifact 仍在
v4	原则化 artifact fix	加入 decoupled band-aperiodicity A	表达力最强，但多一个 control head
v5	最小 artifact fix	Bounded noise filter 变成 crossfade q	不增加 head，但 noise level 与 aperiodicity 耦合

表 4: v1–v5 的推荐叙事方式。

5 评估含义

v1–v3 的比较应主要关注 formant-control error、copy-synthesis quality，以及 spectral tilt 是否能提升自然度而不削弱操控。v3–v5 的比较则应聚焦 high-frequency voiced regions，因为核心假设是：additive excitation 无法移除 coherent high-band harmonics，而 v4 和 v5 可以把一部分 harmonic source 转换为 shaped noise。最有信息量的可视化包括：

1. 一张 lineage diagram，把 v1–v3 显示为 vocal-tract refinements，把 v4–v5 显示为 excitation fixes；

2. 一张 side-by-side excitation-flow figure, 对比 additive、decoupled aperiodicity 和 bounded crossfade;
3. 一个 spectrogram strip, 对比 v3、v4、v5 在 4–8 kHz 区间的表现;
4. 在 voiced frames 上展示 v4 的 $A_n(\omega)$ 和 v5 的 $q_n(\omega)$ 。